Università degli Studi di Milano
Facoltà di Scienze e Tecnologie
Corso di Laurea in informatica

TECNICHE DI MACHINE LEARNING PER LA CLASSIFICAZIONE DI REPERTI ARCHEOLOGICI

Relatore: Prof.ssa Anna Maria Zanaboni

Correlatore: Prof. Dario Malchiodi

Tesi di:
Pietro Scuttari
Matricola: 922822

Anno Accademico 2020-2021

Prefazione

0.1 Descrizione del problema

Il progetto consiste nel classificare un database di analisi di composizione eseguite su dei reperti archeologici. La classificazione è stata eseguita in base all'origine geografica distinguendo i reperti originari di Tarquinia, luogo dove sono stati ritrovati, da quelli di origine diversa. I classificatori presi in considerazione sono per lo più supervisionati e allenati su una porzione dei reperti di cui conoscevamo in partenza l'origine.

0.2 Organizzazione della tesi

La tesi è organizzata come segue:

- Nel capitolo 1 viene introdotto il progetto indicando lo scopo del lavoro e introducendo i concetti principali
- Nel capitolo 2

Ringraziamenti

asdjhgftry.

Indice

Capitolo 1

Algoritmi di machine learning e di classificazione

1.1 Che cos'è il machine learning

Machine learning è un nome che include una varietà di algoritmi che, al contrario di algoritmi tradizionali, non specificano passo per passo come risolvere un certo problema ma migliorano autonomamente gradualmente imparando da dati fino a risolvere correttamente il problema.

Questo approccio ha origini storiche negli anni cinquanta ma solo negli ultimi anni abbiamo visto realizzare il vero potenziale di questo approccio: con l'aumento esponenziale della potenza dei calcolatori e l'enorme quantità di dati oggi disponibili il machine learning è applicato a sempre più problemi, dai veicoli autonomi, agli algoritmi per la selezione della pubblicità a microscopi in grado di identificare cellule cancerogene.

1.2 Cosa sono i problemi di classificazione

La classificazione è un sottoinsieme del machine learning, l'obbiettivo è costruire un modello in grado di mappare un oggetto in ingresso con una categoria. I classificatori si distinguono in due macro categorie quelli a apprendimento supervisionato e quelli a apprendimento non supervisionato: i primi imparano a classificare correttamente a partire da un database di dati etichettati ovvero dove è specificata la categoria corretta, nel secondo caso i dati di addestramento non hanno memorizzato le etichette. Evidentemente il secondo caso è più complesso sia per l'addestramento del modello sia per misurare la sua correttezza. In questo progetto sono stati utilizzati principalmente algoritmi di apprendimento supervisionato.

1.3 Network neurali

I network neurali si ispirano alle reti neuronali biologiche e sono composti da una serie di neuroni collegati fra loro. Questi neuroni in realtà non sono altro che una semplice funzione che prende una serie di valori input e li combina secondo una serie di parametri interni e restituisce un valore finale, tipicamente compreso tra zero e uno.

Il modo in cui i neuroni sono collegati è detto topologia e tipicamente è strutturata in diversi strati collegati fra loro. Il primo detto strato di input in cui abbiamo tanti neuroni quanti dati in ingresso al modello li elaborano secondo la loro funzione e inviano l'output a ogni neurone nello strato successivo. In seguito abbiamo una serie di strati detti nascosti in cui a ogni livello i neuroni ricevono l'output di tutti i neuroni nell'livello precedente e inviano il loro risultato a tutti i neuroni del livello successivo. L'ultimo livello sarà quello di output in cui i neuroni riceveranno l'output dall'ultimo layer nascosto e restituiranno la soluzione. La dimensione del livello di output sarà determinata dalla soluzione desiderata, ad esempio in un problema di classificazione avremmo tipicamente tanti neuroni in uscita quante categorie possibili per la classificazione.

I parametri delle funzioni dei neuroni sono inizializzati con dei valori casuali e vengono perfezionati durante l'apprendimento che nel nostro caso sarà supervisionato: si utilizza un insieme di dati per l'addestramento confrontando l'output con l'etichetta del dato correggendo poi i valori dei parametri dei neuroni per farli avvicinare alla risposta corretta. Il processo viene ripetuto fino a che il modello smette di migliorare.

All'utente viene lasciato il controllo di quelli che vengono detti iperparametri ovvero i parametri che controllano il funzionamento della rete neurale e che non vengono modificati durante l'apprendimento. Alcuni esempi sono la topologia del network neurale, la forma della funzione dei neuroni, la dimensione del passo di apprendimento eccetera.

1.4 K-nearest neighbors

K-nearest neighbors è uno dei modelli più semplici tra quelli usati: invece che creare un modello interno del problema semplicemente memorizza i dati di training e per risolvere un nuovo problema calcola i k valori memorizzati più vicini e restituisce l'etichetta più popolare tra questi. La semplicità di questo approccio lo rende molto veloce, soprattutto nella fase di training, ma potrebbe non essere in grado di classificare un data set in cui la separazione tra le categorie è poco chiara.

Uno dei possibili problemi è la poca uniformità dei dati: se i valori più vicini selezionati sono molti distanti potrebbero non essere rilevanti per la classificazione, per questo è possibile introdurre un peso basato sulla distanza usato per calcolare

l'etichetta più popolare. L'altro iperparametro su cui abbiamo controllo è K ovvero il numero di dati di training considerare per calcolare l'etichetta più probabile. La scelta corretta dipende dal tipo di dati che abbiamo, in particolare un valore maggiore di K sarà utile in un dataset con molto rumore ma produrrà una distinzione meno netta tra le categorie.

1.5 Macchine a vettori di supporto

L'obbiettivo di una macchina a vettori di supporto (SVM) è trovare un iperpiano che separi i dati di training nelle corrette categorie cercando di massimizzare il margine, ovvero la distanza tra l'iperpiano e i data point più vicini di ogni categoria.

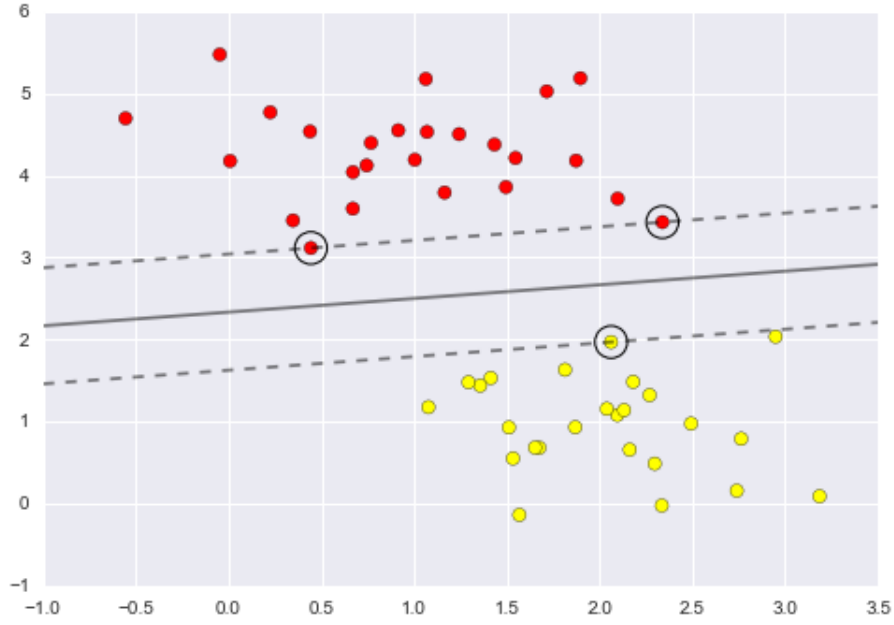

[2]

Non è sempre possibile tracciare un iperpiano lineare per separare le categorie, a volte è necessario aggiungere una dimensione ai dati scalandoli secondo una funzione di kernel che ci permetta poi di tracciare l'iperpiano. Spesso anche utilizzando il kernel non esiste un margine netto tra le categorie e ci serve un modo di permettere un margine meno stringente in cui alcuni dati staranno all'interno del margine, la rigidità del margine è controllata da un parametro C, più grande è C più lasso sarà il margine.

1.6 Alberi di decisione e foreste casuali

L'obbiettivo di questo approccio è costruire un albero di decisione ovvero una serie di decisioni basate sul valore di una caratteristica dei dati che ci porta a separare i dati nelle corrette categorie. Ogni decisione è quindi composta da una caratteristica e una soglia, per ogni decisione sceglieremo la soglia che minimizza un indice di eterogeneità, come l'entropia o l'indice di Gini, e che quindi separa il più possibile le caratteristiche.

Un problema di questo approccio è che tende a fare overfitting soprattutto se aumentiamo la profondità dell'albero. Un modo di ovviare a questo problema è quello di usare le foreste casuali un classificatore che aggrega una serie di alberi di decisioni prendendo la classificazione più popolare tra questi. Vengono allenati più alberi di decisione con diversi sottoinsiemi del training set e la classificazione finale sarà ottenuta prendendo la più popolare tra i diversi alberi di decisione.

1.7 Naive Bayes

Naive Bayes si basa sull'applicazione del teorema di Bayes:

$$P(y \mid x_1, \ldots, x_n) = \frac{P(y)P(x_1, \ldots, x_n \mid y)}{P(x_1, \ldots, x_n)}$$

considerando y come appartenere a una data categoria e x_n come le caratteristiche dei nostri dati. Perché il teorema sia corretto è necessario che le x_n siano tra loro indipendenti, questo non è sempre vero ma in problemi reali si può tipicamente assumerlo come vero e ottenere comunque buoni risultati. Possiamo stimare $P(y)$, $P(x_1, \ldots, x_n \mid y)$ e $P(x_1, \ldots, x_n)$ dal training set e quindi classificare i nuovi dati come la categoria a cui è più probabile che appartengono.

1.8 K-means

K-means è l'unico algoritmo non supervisionato usato in questo progetto e si basa sul dividere il training set in K categorie scegliendo K punti detti baricentri e assegnando ogni punto alla categoria del baricentro più vicino. La posizione dei baricentri viene ottimizzata cercando di minimizzare la somma delle distanze quadratiche tra i dati del training set e il loro baricentro più vicino.

Essendo questo un algoritmo non supervisionato non è nota l'associazione tra baricentro e categoria reale e sarà quindi necessario ristabilire questa associazione ad esempio associando ogni baricentro alla categoria più presente nel suo insieme.

Capitolo 2

Il problema affrontato

2.1 Descrizione dei dati

2.2 Ambiente software

2.3 Schema delle prove

2.3.1 Repeated hold out

2.3.2 Convalida incrociata

2.3.3 Griglia di ricerca

Capitolo 3

Risultati

3.1 Valutazione combinata

Capitolo 4

Conclusioni

Bibliografia

[1] D. Kriesel, A brief introduction to neural networks, available at http://www.dkriesel.com, 2007.

[2] Jake VanderPlas, Python Data Science Handbook, O'Reilly Media, aviable at https://jakevdp.github.io/PythonDataScienceHandbook/, 2016